國立臺南大學

資訊工程學系碩士班

碩士論文

智慧物聯網下整合無人機與智慧反射板之通訊效能優化：
深度強化學習方法

Optimizing Communication Performance for Smart IoT by Integrating UAV and Reconfigurable Intelligent Surface: A Deep Reinforcement Learning Approach

指導教授：陳宗禧　博士

研究生：　黃曜晨

中華民國一一四年六月

智慧物聯網下整合無人機與智慧反射板之通訊效能優化：深度強化學習方法

Optimizing Communication Performance for Smart IoT by Integrating UAV and Reconfigurable Intelligent Surface: A Deep Reinforcement Learning Approach

by

Yao-Chen Huang

A thesis submitted in partial fulfillment of the requirements
for the degree of Master of Science
in the Department of Computer Science and Information Engineering
in the College of Science and Engineering
at the National University of Tainan
Tainan, Taiwan

Advisor: Professor Zong-Sian Chen

June 2025
中華民國一一四年六月

摘　要

隨著智慧物聯網（IoT）應用的普及，如何在結構複雜的都市環境中為大量用戶提供可靠的無線連接，成為下一代通訊網路的核心挑戰。傳統地面基地台易受建築物遮蔽，導致非視距（NLOS）傳輸問題，嚴重影響訊號品質。為此，本研究提出一套整合無人機（UAV）、可重構智慧表面（RIS）與深度強化學習（DRL）的協同控制系統，旨在動態優化都市環境中的資料收集與通訊效能。

本研究的核心貢獻在於設計並實現了一套更貼近現實的智慧化網路部署框架。首先，我們引入一種基於 DBSCAN（具有雜訊的應用程式基於密度的空間聚類）演算法的用戶群體化機制，將大量地面 IoT 裝置自動分群。隨後，利用 Voronoi 圖生成 RIS 的候選停留點，確保其部署的合理性。此舉不僅模擬了真實世界中用戶的群聚特性，也為後續的資源分配提供了結構化基礎。

在此基礎上，我們將 UAV 搭載 RIS 於預設停留點服務特定用戶群體的問題，建模為一個旨在最大化系統總傳輸速率的 DRL 優化任務。我們系統性地評估了多種先進的 DRL 演算法，包括 Soft Actor-Critic（SAC）、深度確定性策略梯度（DDPG）、近端策略優化（PPO），以及針對硬體非理想性（相位依賴振幅）而設計的 Beta-Space Exploration SAC。為確保 DRL 模型訓練的有效性，我們設計了一套「虛擬用戶補齊機制」，使得模型無論服務多少真實用戶，都能在固定的動作與狀態空間下穩定學習。

實驗結果表明，在我們所建構的、更具挑戰性的 NLOS 主導場景中，所有 DRL 方法均顯著優於隨機相位基準。其中，Beta-Space Exploration SAC 演算法展現出最佳的性能與魯棒性，其平均傳輸速率在 L=64 的配置下達到 3.35 bps/Hz，顯著超越標準 SAC、DDPG 及 PPO。本研究不僅驗證了 UAV-RIS 系統的可行性，更透過引入 DBSCAN 用戶群體化與先進 DRL 演算法比較，提供了一套從環境生成、模型訓練到性能評估的完整框架，為未來智慧城市通訊網路的自適應部署提供了重要的技術參考與實證依據。

關鍵字：可重構智慧表面、深度強化學習、無人機、用戶分群、DBSCAN、非視距通訊、資源優化

ABSTRACT

With the proliferation of smart Internet of Things (IoT) applications, providing reliable wireless connectivity for numerous users in structurally complex urban environments has become a core challenge for next-generation communication networks. Traditional terrestrial base stations are susceptible to building blockages, leading to non-line-of-sight (NLOS) transmission issues that severely degrade signal quality. To address this, this study proposes a cooperative control system that integrates an Unmanned Aerial Vehicle (UAV), a Reconfigurable Intelligent Surface (RIS), and Deep Reinforcement Learning (DRL) to dynamically optimize data collection and communication performance in urban settings.

The key contribution of this research lies in the design and implementation of an intelligent network deployment framework that more closely mirrors reality. First, we introduce a user clustering mechanism based on the DBSCAN (Density-Based Spatial Clustering of Applications with Noise) algorithm to automatically group a large number of ground-based IoT devices. Subsequently, Voronoi diagrams are used to generate candidate anchor points for the RIS, ensuring a rational deployment. This approach not only simulates the clustering characteristics of real-world users but also provides a structured foundation for subsequent resource allocation.

Building on this framework, we model the problem of a UAV-mounted RIS serving specific user clusters at predefined anchor points as a DRL optimization task aimed at maximizing the system's sum-rate. We systematically evaluate several advanced DRL algorithms, including Soft Actor-Critic (SAC), Deep Deterministic Policy Gradient (DDPG), Proximal Policy Optimization (PPO), and Beta-Space Exploration SAC, which is specifically designed for hardware non-idealities (Phase-Dependent Amplitude). To ensure the effectiveness of DRL model training, we devised a "virtual user complementation mechanism," enabling the model to learn stably within a fixed action and state space, regardless of the number of real users being served.

The experimental results demonstrate that in the more challenging NLOS-dominant scenarios constructed, all DRL-based methods significantly outperform the random phase baseline. Among them, the Beta-Space Exploration SAC algorithm exhibits the best performance and robustness, achieving an average transmission rate of 3.35 bps/Hz with an L=64 configuration, markedly surpassing standard SAC, DDPG, and PPO. This study

not only validates the feasibility of the UAV-RIS system but also, through the introduction of DBSCAN user clustering and a comparison of advanced DRL algorithms, provides a complete framework—from environment generation and model training to performance evaluation. This work offers a crucial technical reference and empirical evidence for the adaptive deployment of future smart city communication networks.

Keywords: Reconfigurable Intelligent Surface (RIS), Deep Reinforcement Learning (DRL), Unmanned Aerial Vehicle (UAV), User Clustering, DBSCAN, NLOS Communication, Resource Optimization

謝辭

在撰寫本論文的過程中，我獲得許多師長與親友的幫助與支持，謹此致上誠摯的謝意。首先感謝指導教授陳宗禧博士，在研究過程中給予我悉心的指導與寶貴的建議，無論在學術思考、實驗設計或論文撰寫方面，皆受益良多。教授的嚴謹與啟發，是本研究得以順利完成的關鍵。此外，感謝口試委員們在論文審查期間提出的寶貴意見，讓本論文的內容更加完善。同時，感謝系上各位授課老師與實驗室同儕在研究期間的協助與鼓勵，使我能在學術與人格上有所成長。最後，感謝我的家人，在我求學與研究歷程中提供無私的支持與陪伴，是我堅持不懈的最大動力。

黃曜晨謹誌

于國立臺南大學

中華民國一一四年六月

Contents

中文摘要 **i**

英文摘要 **ii**

謝辭 **iv**

圖目錄 **vii**

表目錄 **viii**

1 緒論 **1**

1.1 研究背景 1

1.2 研究挑戰與目的 2

1.3 研究貢獻 3

1.4 論文架構 3

2 文獻回顧與背景技術 **5**

2.1 UAV-RIS 協同通訊主題式評析 5

2.1.1 深化基礎：先進建模與穩健性 5

2.1.2 擴展優化視界：從靜態控制到動態軌跡 6

2.1.3 拓寬應用範疇：新興範式與性能指標 7

2.1.4 邁向次世代前沿：生成式 AI 與聯邦學習的整合 7

2.1.5 UAV 智慧網路的演化典範：整合、語義與韌性 8

2.2 深度強化學習背景技術 9

2.2.1 深度確定性策略梯度 (DDPG) 9

2.2.2 近端策略優化 (PPO) 10

3 系統模型與問題定義 **12**

3.1 系統架構 12

3.2 通道模型 13
3.2.1 相位依賴振幅 (PDA) 模型 14
3.2.2 通道估計誤差 14
3.3 問題定義 15

4 方法設計與訓練架構 **16**
4.1 智慧城市環境生成機制 16
4.2 強化學習框架設計 17
4.3 深度強化學習演算法 17
4.4 虛擬用戶補齊機制 18

5 實驗結果與分析 **19**
5.1 實驗參數配置 19
5.2 模型訓練收斂性分析 20
5.3 NLOS 場景性能比較分析 22
5.3.1 各停留點的性能比較 23
5.3.2 所有停留點的平均性能分析 25
5.4 本章總結 28

6 結論與未來展望 **29**
6.1 研究結論 29
6.2 後續研究建議 30

參考文獻 **31**

List of Figures

3.1 UAV 搭載 RIS 輔助的 MU-MISO 通訊系統模型 13

5.1 模型訓練收斂曲線 ($L = 16$) 20
5.2 模型訓練收斂曲線 ($L = 32$) 21
5.3 模型訓練收斂曲線 ($L = 64$) 21
5.4 NLOS 測試環境佈局 (BS、22 個 RIS 停留點、80 個 IoT 裝置) 23
5.5 各停留點的服務速率比較 (L=16, NLOS) 24
5.6 各停留點的服務速率比較 (L=32, NLOS) 24
5.7 各停留點的服務速率比較 (L=64, NLOS) 25
5.8 所有停留點的平均性能比較 (L=16, NLOS) 26
5.9 所有停留點的平均性能比較 (L=32, NLOS) 26
5.10 所有停留點的平均性能比較 (L=64, NLOS) 27

List of Tables

5.1 模擬環境與系統參數設定 19
5.2 DRL 演算法超參數設定 20

Chapter 1

緒論

1.1 研究背景

隨著物聯網（IoT）技術的飛速發展與智慧城市概念的逐步落地，如何在結構複雜、障礙物林立的都市環境中，為海量分散的 IoT 裝置提供高效、可靠的無線連接，已成為當前及未來通訊領域的核心挑戰 [2, 3]。傳統的地面基地台（Base Station, BS）部署方式，在高樓密集的區域常因嚴重的訊號遮蔽效應而面臨非視距（Non-Line-of-Sight, NLOS）傳播的困境，導致通訊品質下降與覆蓋盲區的產生 [4]。

為突破地面基礎設施的物理限制，無人機（Unmanned Aerial Vehicle, UAV）因其卓越的機動性、靈活的部署能力以及建立視距（Line-of-Sight, LoS）鏈路的潛力，被視為一種極具前景的空中通訊平台解決方案 [5, 6]。然而，單純依賴 UAV 作為空中中繼站，其自身與地面 BS 的通訊鏈路（回程鏈路）仍可能受到高層建築的阻礙，限制了其整體效能。

近年來，可重構智慧表面（Reconfigurable Intelligent Surface, RIS）作為一項革命性的 6G 候選技術，為解決上述挑戰提供了全新的思路 [1, 7]。RIS 由大量低成本、可被動調控的反射元件構成，能透過軟體編程，智慧地調控入射電磁波的相位與振幅，從而重塑無線傳播環境，創建出高品質的虛擬 LoS 鏈路 [8, 9]。將 RIS 搭載於 UAV 上，形成一個機動性與通道調控能力兼備的空中智慧反射平台，不僅能充分利用 UAV 的位置優勢，更能動態地克服複雜三維空間中的訊號傳播障礙，為地面訊號盲區的 IoT 裝置建立可靠的通訊橋樑 [2]。

然而，UAV-RIS 系統的協同控制是一個高度複雜的非凸優化問題。傳統的數學優化方法在面對動態變化的環境時，往往難以求得即時且高效的解 [1, 2]。深度強化學習（DRL）憑藉其強大的環境感知、自主決策與策略學習能力，為解決此類問題提供了強而有力的工具 [4]。因此，本研究的核心動機在於：探索如何利用先進的 DRL 演算法，

解決 UAV 於固定停留點時，RIS 相位與 BS 波束成形的聯合控制問題。我們不僅考慮了真實的硬體限制與通道不確定性，更引入了基於 DBSCAN 的用戶群體化機制，以模擬更真實的用戶分佈場景，旨在最大化整體 IoT 網路的資料收集效率。

1.2 研究挑戰與目的

基於上述背景，本研究旨在解決 UAV 搭載 RIS 於智慧城市進行資料收集時所面臨的核心挑戰，並達成以下研究目的：

1. 研究挑戰：

    - 高維度聯合優化：在 UAV 抵達停留點後，需同時優化基地台的傳輸波束成形與 RIS 的反射相位，此為一個高維度的混合整數非凸問題，求解難度極高 [1, 2]。
    - 真實環境的複雜性與非理想條件：實際的城市環境中，用戶分佈並非均勻，而是呈現群聚特性。同時，RIS 硬體存在相位與振幅耦合的非理想效應（Phase-Dependent Amplitude, PDA），且通道狀態資訊（CSI）的獲取常有誤差。這些因素都對控制策略的有效性與魯棒性提出了更高要求 [1, 12]。
    - **DRL** 模型的泛化與學習效率：若 DRL 模型的訓練數據過於隨機或脫離物理現實，模型可能無法學習到相位控制與訊號提升之間的直接關聯，導致訓練效率低下且泛化能力不足，難以應對真實場景 [26]。

2. 研究目的：

    - 設計基於用戶群體化的 **DRL** 協同控制系統：開發一套整合 DBSCAN 用戶分群與 DRL 的框架。該框架能夠在 UAV 抵達為特定用戶群體服務的停留點後，自動聯合優化 RIS 相位與 BS 波束成形，以最大化系統的總傳輸速率。
    - 建立結構化的智慧城市模擬環境：提出一種創新的、結合用戶群體化與物理約束的場景生成方法。該方法利用 DBSCAN 演算法模擬用戶的群聚行為，並透過 Voronoi 圖生成合理的 RIS 部署位置，使模擬環境更貼近現實，從而提升 DRL 模型訓練的針對性。
    - 全面評估多種 **DRL** 演算法的性能：系統性地比較多種主流及先進 DRL 演算法，包括 Soft Actor-Critic（SAC）、深度確定性策略梯度（DDPG）、近

端策略優化（PPO）以及針對硬體缺陷設計的 Beta-Space Exploration SAC，在理想與非理想（含 PDA 與 CSI 誤差）條件下的性能差異。

- 驗證系統在 **NLOS** 主導場景下的效益：特別針對更具挑戰性的非視距（NLOS）通訊場景，深入分析所提方法對提升系統性能與保障通訊公平性的實際效益。

1.3 研究貢獻

本研究的主要貢獻可歸納如下：

- 創新的 **DBSCAN** 用戶群體化環境框架：本研究的核心創新之一是引入了基於 DBSCAN 的用戶群體化機制，並結合 Voronoi 圖來生成 RIS 的候選停留點。此舉使模擬環境從隨機分佈轉向結構化的群體服務模式，不僅更符合真實智慧城市的應用場景，也為 DRL 模型的訓練提供了更具意義的結構化數據，有效提升了學習效率。

- 多種先進 **DRL** 演算法的綜合比較：本研究首次在 UAV-RIS 場景下，對 SAC、DDPG、PPO 以及 Beta-Space Exploration SAC 等多種主流與先進的 DRL 演算法進行了全面且公平的性能比較。實驗結果為不同演算法在該特定問題上的適用性提供了寶貴的實證數據與深入見解。

- **NLOS** 場景的深度效能驗證：本研究特別設計並評估了更具挑戰性的 NLOS 主導場景，即用戶與基地台之間無直接視距，通訊完全依賴 RIS 反射。實驗結果有力地證明了 Beta-Space Exploration SAC 演算法在該惡劣環境下的卓越性能與魯棒性，突顯了其在解決現實世界訊號遮蔽問題上的應用潛力。

- 提出並驗證「虛擬用戶補齊機制」: 為解決真實服務場景中用戶數量動態變化的問題，我們設計了一套「虛擬用戶補齊機制」。該機制確保 DRL 代理始終在一個固定的狀態與動作空間中進行學習，有效解決了因用戶數變化導致的輸入維度不一致問題，顯著增強了模型的訓練穩定性與適用性。

1.4 論文架構

本論文共分為六章，各章節內容概述如下：

- 第一章緒論：說明研究背景、動機、所面臨的挑戰、研究目的及主要貢獻，並簡述全文架構。
- 第二章文獻回顧與背景技術：系統性地梳理 UAV-RIS 協同通訊的近期研究進展，並介紹本研究中作為比較基準的 DRL 演算法，包括 DDPG 與 PPO。
- 第三章系統模型與問題定義：詳細闡述本研究的系統架構，包括 UAV-RIS 輔助的 MU-MISO 通訊模型、通道模型、以及最大化總傳輸速率的數學問題定式。
- 第四章方法設計與訓練架構：介紹本研究採用的 DRL 演算法，並詳細闡述核心的 DBSCAN 用戶群體化環境生成機制、Voronoi 候選點選擇、以及虛擬用戶補齊機制。
- 第五章實驗結果與分析：呈現並分析模擬實驗的結果，包括各 DRL 模型的收斂性比較、在不同 RIS 規模與 NLOS 條件下於各停留點的性能表現，並提供深入的討論。
- 第六章結論與未來展望：總結本研究的主要發現與貢獻，並對未來的研究方向提出具體建議。

Chapter 2

文獻回顧與背景技術

無人機（UAV）與可重構智慧表面（RIS）的協同通訊是一個發展極其迅速的領域。本章旨在將本研究置於當前學術研究的前沿，系統性地梳理相關領域的關鍵研究。我們將圍繞五大核心主題展開評析：(1) 深化基礎：先進建模與穩健性；(2) 擴展優化視界：從靜態控制到動態軌跡；(3) 拓寬應用範疇：新興範式與性能指標；(4) 邁向次世代前沿：生成式 AI 與聯邦學習的整合；以及 (5) UAV 智慧網路的演化典範：整合、語義與韌性。此外，本章也將介紹本研究中作為比較基準的深度強化學習（DRL）演算法，為後續的實驗比較提供必要的理論背景。

2.1 UAV-RIS 協同通訊主題式評析

2.1.1 深化基礎：先進建模與穩健性

本研究已意識到理想化模型與物理現實之間的差距，並透過其 SAC-Mismatch 模型和 Beta-Space Exploration SAC 演算法，在處理硬體缺陷方面邁出了重要一步。近期文獻致力於從更深層次、更多維度來應對硬體限制與通道不確定性，以構建更具穩健性的 UAV-RIS 系統。

真實的硬體限制遠不止相位依賴振幅（PDA）效應。近期的研究開始關注更為棘手的硬體損傷，例如相位雜訊（phase noise），其源於振盪器等硬體元件的不穩定性，會導致 RIS 反射係數的相位產生隨機偏差，嚴重破壞波束成形的精句話性。Gurgunoglu 等人 (2023) 的研究不僅對此進行了建模，還分析了其對系統性能的影響，並推導了相應的功率縮放定律，為系統設計者提供了性能邊界參考 [11]。

與此同時，如何應對不完美的通道狀態資訊（CSI）也是提升系統穩健性的關鍵。本研究的 SAC-Mismatch 模型模擬了 CSI 存在誤差的情境，而學術界正從另一條路徑

——穩健優化（robust optimization）——來解決此問題。此方法在設計階段就將不確定性作為核心約束。例如，Xiong 等人 (2024) 在研究 STAR-RIS 輔助的無線資訊與能量同傳（SWIPT）系統時，明確考慮了有界和統計 CSI 誤差模型，旨在確保即使在最壞的 CSI 誤差情況下，系統性能也能維持在可接受的水平 [12]。

本研究的「物理限制驅動的訓練環境生成」機制，與學術界致力於解決 RIS 通道估計難題的趨勢不謀-erhe。為克服傳統通道估計方法導頻開銷巨大和精度不足的挑戰，研究人員正開發更高效的技術。例如，Huang 等人 (2024) 提出的「流形優化賦能的雙時間尺度通道估計」方法，利用 RIS 輔助通道固有的低秩結構，將高維估計問題轉化為低維流形上的優化，大幅減少導頻開銷 [10]。更進一步，最新的「任務導向」（task-oriented）通訊設計理念認為，系統無需追求對 CSI 的完美估計，而是應學習獲取「足夠好」的資訊以完成主要任務。本研究的物理驅動訓練框架可被視為朝向此高效學習範式邁出的重要一步。

2.1.2 擴展優化視界：從靜態控制到動態軌跡

本研究的重點是當 UAV 懸停於預設「停留點」時的資源優化，這是一個關鍵且基礎的問題。然而，UAV 最大的優勢在於其機動性，因此將 UAV 的軌跡規劃納入優化框架，是該領域一個活躍的演進方向。

將 UAV 的軌跡視為待優化變數，會產生高度耦合的非凸問題。近期的研究廣泛探討了此問題，例如 Pang 等人 (2022) 和 Zhuang 等人 (2024) 旨在透過聯合設計 UAV 軌跡與 RIS 配置，最大化系統的保密率或可靠性 [13, 18]。Huang 等人 (2024) 則在主動式 IRS 輔助的 UAV 中繼網路中，以最大化平均總速率為目標進行聯合優化 [17]。

然而，使用單一 DRL 智能體直接解決此聯合優化問題會面臨「維度災難」。為此，階層式 DRL（Hierarchical DRL）方法應運而生。Shi 等人 (2021) 清晰地闡述了此思想，他們將複雜問題解耦為兩個不同時間尺度的子問題：一個負責規劃長時程全局軌跡的高層智能體，以及每個 UAV 上負責短時程資源分配的低層智能體 [14]。這種階層式架構不僅降低了決策複雜度，也為未來研究提供了清晰可行的方法論路徑。

當場景擴展到多 UAV 群時，問題轉變為多智能體系統（MAS）的協同。多智能體深度強化學習（MADRL）為此提供了理論框架。Zhao 等人 (2022) 和 Xie 等人 (2024) 的工作是此領域的典型範例，他們分別應用 MADRL 解決多 UAV 輔助的 MEC 任務卸載和集成感知與通訊（ISAC）任務 [15, 16]。為了解決多智能體環境中的「非平穩性」挑戰，研究人員引入了基於「中心化訓練，去中心化執行」（CTDE）範式的先進算法。在離線訓練階段，所有智能體共享全局資訊以訓練一個「中心化評論家」網路；在線

上執行階段，每個智能體僅依賴局部觀測做出即時決策。CTDE 範式完美地平衡了學習效率與執行效率，是實現高效多智能體協同的關鍵。

2.1.3 拓寬應用範疇：新興範式與性能指標

本研究以最大化系統總傳輸速率（Sum-Rate）為核心目標，但隨著智慧城市應用的多樣化，單一速率指標已不足以全面衡量系統效能。一系列新興應用範式和性能指標正在湧現。

- 高能效運營與無線能量同傳 **(SWIPT):** 對於電池供電的 UAV，能量效率（Energy Efficiency, EE）是一個關鍵指標，優化目標從最大化速率轉向最大化每焦耳傳輸的位元數 [19, 20]。与此相關的 SWIPT 技術，利用射頻信號同時傳輸資訊和能量，為低功耗物聯網設備進行無線充電。

- 提升數據新鮮度 **(**資訊年齡**, AoI):** 在交通監控、災害預警等場景中，數據的「新鮮度」至關重要。資訊年齡（Age of Information, AoI）正是為量化此指標而生。最小化 AoI 與最大化吞吐量是截然不同的目標 [22]。

- 整合邊緣運算 **(MEC):** UAV 是理想的行動邊緣運算（MEC）伺服器載體，可為地面用戶提供低延遲的任務卸載服務。大量的近期研究聚焦於聯合優化任務卸載決策、UAV 軌跡與通訊資源，以最小化延遲或能耗 [15, 21]。

- 保障空域安全 **(PLS** 與隱蔽通訊**):** 空對地鏈路易受竊聽，物理層安全（PLS）技術旨在利用通道物理特性保障通訊機密性。其優化目標通常是最大化「保密率」。更進一步的「隱蔽通訊」則要讓監測者無法察覺通訊行為本身的存在 [23, 24]。

這些新興範式揭示了通訊、運算、控制與安全深度融合的趨勢，為本研究的未來方向提供了廣闊的視野。

2.1.4 邁向次世代前沿：生成式 AI 與聯邦學習的整合

更新的人工智慧範式正被應用於無線通訊領域，有望從根本上改變 UAV-RIS 系統的設計與部署方式。

- 生成式 **AI (Generative AI):** 傳統 DRL 學習從「狀態」到「動作」的映射，而生成式 AI（如擴散模型）則學習「最優策略的數據分佈」。Sun 等人 (2025) 在其綜述中指出，GAI 可被用於動態網路拓撲自適應和資源管理等方面 [25]。Wu 等人

(2025) 提出利用擴散模型在離線階段生成高品質的初始策略，再於線上進行少量微調，極大提升了 DRL 的響應速度和泛化能力 [26]。此範式對於解決 UAV-RIS 系統中的「模擬到現實的鴻溝」(Sim2Real Gap) 具有深遠意義。

- 聯邦學習 **(Federated Learning):** 隨著 UAV 群和大規模物聯網的部署，數據產生變得高度分散，集中式訓練帶來巨大的通訊開銷和隱私問題。聯邦學習 (FL) 允許客戶端在不共享原始數據的情況下，協同訓練一個全局模型。然而，在無線環境中實現高效 FL，需解決模型更新傳輸佔用資源的問題。Ni 等人 (2022) 提出利用「空中計算」(AirComp) 並結合 RIS 來高效執行模型聚合，提升 FL 的通訊效率 [27, 28, 29]。將 FL 整合到 UAV-RIS 框架中，將為實現大規模、去中心化、隱私保護的智慧網路控制開闢全新維度。

2.1.5 UAV 智慧網路的演化典範：整合、語義與韌性

除了上述技術的深化與拓展，UAV 智慧網路的研究正經歷著根本性的典範轉移。本研究深入鑽研並解決了 UAV-RIS 系統中的通訊效能優化問題，而最新的學術前沿則將此「優化」問題推向了更宏大的維度，體現在三個關鍵的演化方向上：

- 從通訊到功能 **(From Communication to Functionality):** 此前沿擴展了 UAV 的任務範疇，使其從被動的通訊中繼演變為具備雙重功能的主動平台。此趨勢的具體體現即為「整合感知與通訊」(Integrated Sensing and Communication, ISAC) 技術 [30]。ISAC 旨在打破傳統雷達感知與無線通訊各自獨立運作的模式，透過共享硬體與波形，在提升頻譜與能量效率的同時，實現「為通訊而感知」的協同增效。本研究中的 DBSCAN 用戶群體化可視為一種離線的、初階的感知實踐，而 ISAC 則將其動態化，使 UAV 能持續感知環境，並利用即時資訊來動態優化通訊策略。

- 從吞吐量到意義 **(From Throughput to Meaning):** 此前沿代表了通訊成功定義的「典範轉移」。優化目標不再是最大化數據傳輸速率 (Shannon-Hartley 觀點)，而是最大化任務的完成效率與效果。此轉變的具體體現即為「語義通訊」(Semantic Communication) [31]。在語義通訊框架下，系統傳輸的不再是原始數據位元，而是與任務相關的、高度壓縮的「語義特徵」。例如，Hu 等人 (2025) 在多無人機協作網路中，聯合優化 UAV 軌跡與待傳輸的語義符號數量，旨在最大化體驗品質 (QoE) 與最小化傳輸成本的加權和，而非傳統的總傳輸速率 [31]。

- 從理想條件到對抗現實 **(From Ideal Conditions to Adversarial Reality):** 此前沿將前兩者置於更複雜、更具挑戰性的對抗性操作環境中，要求系統具備前所未有的智慧與韌性。此趨勢的具體體現即為「語義抗干擾技術」[32]。惡意的電子干擾能輕易癱瘓傳統通訊鏈路，而語義通訊因其傳輸數據量小、內在錯誤容忍度高的特性，展現出天然的抗干擾優勢。例如，Liu 等人 (2025) 採用先進的 MADRL 演算法，訓練 UAV 智能體在存在惡意干擾的環境下進行合作，聯合優化飛行軌跡與頻道選擇，從而主動規避干擾，在確保任務完成（低延遲）的同時，維持系統的韌性 [32]。

這三大前沿共同勾勒出下一代 UAV 網路的發展藍圖：一個功能整合、目標導向且具備高度韌性的智慧化空天地一體化網路。

2.2 深度強化學習背景技術

本研究採用了多種 DRL 演算法進行性能比較。除了在第四章將詳細介紹的 SAC 及其變體外，我們還引入了 DDPG 和 PPO 作為重要的比較基準。

2.2.1 深度確定性策略梯度 (DDPG)

深度確定性策略梯度（Deep Deterministic Policy Gradient, DDPG）是一種為連續動作空間設計的 off-policy、model-free 的 DRL 演算法。DDPG 巧妙地結合了深度 Q 網路（DQN）和 Actor-Critic 框架的優點。其核心思想是：

- **Actor-Critic** 架構： DDPG 包含一個 Actor 網路和一個 Critic 網路。Actor 網路（策略網路）負責學習一個從狀態到確定性動作的映射 $\mu(s|\theta^\mu)$。Critic 網路（價值網路）則負責評估 Actor 所選動作的價值 $Q(s,a|\theta^Q)$。

- 目標網路與軟更新：為了提升訓練的穩定性，DDPG 為 Actor 和 Critic 網路分別創建了結構相同的目標網路（Target Networks）。目標網路的參數並不直接透過反向傳播更新，而是透過「軟更新」的方式，緩慢地複製主網路的參數：$\theta' \leftarrow \tau\theta + (1-\tau)\theta'$，其中 $\tau \ll 1$。這使得價值目標的更新更加平滑，避免了訓練過程中的劇烈震盪。

- 經驗回放：與 DQN 類似，DDPG 使用一個經驗回放緩衝區（Replay Buffer）來儲存代理與環境互動的轉移（transition）樣本 (s,a,r,s')。在訓練時，從緩衝區

中隨機採樣一個小批次（mini-batch）的數據來更新網路，這打破了樣本之間的時序相關性，提升了數據利用率和學習穩定性。

- 探索機制：由於 Actor 產生的是確定性動作，為了確保充分的探索，DDPG 在訓練過程中會對 Actor 輸出的動作上疊加一個隨機噪聲，如 Ornstein-Uhlenbeck 過程或高斯噪聲。

DDPG 因其結構相對簡單且在許多連續控制任務中表現出色，成為了一個經典的 DRL 基準演算法。

2.2.2 近端策略優化 (PPO)

近端策略優化（Proximal Policy Optimization, PPO）是一種 on-policy 的 DRL 演算法，以其卓越的穩定性、易於實現和調參的特性而廣受歡迎。與 DDPG 不同，PPO 旨在直接優化策略網路，並透過一種巧妙的機制來限制每次策略更新的幅度，防止因更新步長過大而導致性能崩潰。

- **On-Policy 學習**：PPO 是一種 on-policy 演算法，意味著它使用當前策略採集到的數據來進行更新。通常，代理會與環境互動一個固定的步數（例如 2048 步），收集一個軌跡（trajectory）批次，然後使用這些數據對策略進行多輪（epochs）更新。更新完成後，舊的數據將被丟棄。

- **Clipped Surrogate Objective**：這是 PPO 的核心創新。PPO 的目標函數引入了一個「裁剪」機制。它首先計算新舊策略對同一動作的輸出概率之比 $r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$。然後，將目標函數限制在一個範圍內：

$$L^{CLIP}(\theta) = \mathbb{E}_t[\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t)] \tag{2.1}$$

  其中 $\hat{A}_t$ 是優勢函數（Advantage Function）的估計，ϵ 是一個小的超參數（例如 0.2）。這個裁剪操作確保了新策略不會與舊策略偏離太遠，從而保證了更新的穩定性。

- **廣義優勢估計 (GAE)**：PPO 通常結合廣義優勢估計（Generalized Advantage Estimation, GAE）來計算優勢函數 $\hat{A}_t$。GAE 透過引入一個參數 $\lambda \in [0, 1]$，在無偏的蒙地卡羅估計和有偏但方差較小的時序差分（TD）估計之間進行權衡，從而得到一個方差較小的優勢估計值。

- 價值函數與熵獎勵： PPO 的總損失函數通常還包含一個價值函數的均方誤差損失（用於訓練 Critic）和一個熵獎勵項（用於鼓勵探索），以進一步提升性能和穩定性。

PPO 因其穩健的性能和相對簡單的實現，已成為許多複雜控制任務的首選 DRL 演算法之一。

Chapter 3

系統模型與問題定義

本章旨在建立本研究的理論基礎。首先，我們將詳細描述一個由 UAV 搭載 RIS 輔助的下行多用戶多輸入單輸出（MU-MISO）通訊系統架構，此架構特別考慮了都市環境中用戶的群聚特性。接著，我們將引入一個綜合考慮了真實世界物理效應的通道模型，包括 RIS 的相位依賴振幅（PDA）特性以及通道估計誤差。最後，基於此模型，我們將該問題定式化為一個旨在最大化系統總傳輸速率的聯合優化問題。

3.1 系統架構

我們考慮一個部署於城市環境中的下行 MU-MISO 通訊系統，如圖 3.1 所示。此系統旨在為分散的物聯網（IoT）裝置提供高效的資料收集服務，其關鍵組成部分如下：

- 一個基地台 **(Base Station, BS):** 位於場景中央，高度固定為 15 公尺，配備 M 根天線。
- 大量 **IoT** 裝置**:** 總計 80 個單天線 IoT 裝置隨機分佈於一個 100x100 平方公尺的城市環境中。這些裝置被設定為處於基地台的非視距（NLOS）區域。
- 用戶群體 **(User Clusters):** 為了模擬真實世界中用戶的群聚特性並使服務更具針對性，這 80 個 IoT 裝置將透過 DBSCAN 演算法被劃分為多個用戶群體。DRL 代理的目標是在每個時間步服務一個用戶群體，我們設定每個服務群體的大小為 $K = 4$ 個用戶。
- 一架搭載 **RIS** 的 **UAV:** RIS 由 L 個可獨立調控相位的被動反射元件組成。UAV 的飛行高度固定為 15 公尺，並在一系列由 Voronoi 圖生成的候選停留點之間移動。本研究聚焦於當 UAV 抵達某個停留點後的靜態場景，此時 RIS 被啟用以服務該停留點覆蓋範圍內的一個特定用戶群體。

在此設定下，BS 與地面用戶群體之間的直接鏈路因建築物遮蔽而中斷。RIS 的角色是建立一個從 BS 經由 RIS 再到目標用戶群體的級聯反射鏈路，從而繞過障礙物，克服 NLOS 衰減，提升通訊品質。

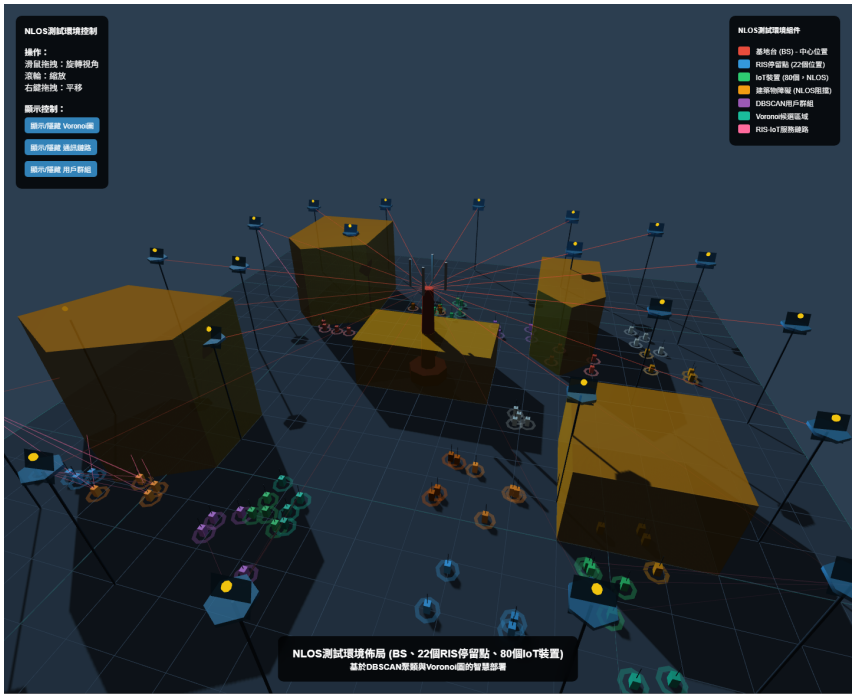


Figure 3.1: UAV 搭載 RIS 輔助的 MU-MISO 通訊系統模型

3.2 通道模型

訊號從基地台傳送至第 k 個用戶的接收訊號 z_k 可表示為 BS-RIS-User 的級聯通道，其數學模型如下 [1]：

$$z_k = \mathbf{h}_k^T \mathbf{\Phi} \mathbf{H} \mathbf{G} \mathbf{x} + w_k \tag{3.1}$$

其中：

- $\mathbf{x} \in \mathbb{C}^{K \times 1}$ 是傳送給 K 個用戶的數據流，滿足 $\mathbb{E}[\mathbf{x}\mathbf{x}^H] = \mathbf{I}_K$。
- $\mathbf{G} \in \mathbb{C}^{M \times K}$ 是基地台的傳輸波束成形（預編碼）矩陣。
- $\mathbf{H} \in \mathbb{C}^{L \times M}$ 是 BS 到 RIS 的通道矩陣。
- $\mathbf{\Phi} = \mathrm{diag}(\phi_1, \ldots, \phi_L) \in \mathbb{C}^{L \times L}$ 是 RIS 的對角反射矩陣，其中 ϕ_l 是第 l 個元件的反射係數。
- $\mathbf{h}_k \in \mathbb{C}^{L \times 1}$ 是 RIS 到第 k 個用戶的通道。

- $w_k \sim \mathcal{CN}(0, \sigma_w^2)$ 是在第 k 個用戶端的加性高斯白雜訊（AWGN），σ_w^2 為其變異數。

通道矩陣 $\mathbf{H}$ 與 $\mathbf{h}_k$ 的元素遵循萊斯衰落（Rician fading）模型，以同時捕捉 LoS 與 NLoS 分量。

為簡化表示，我們將 BS-RIS-User 鏈路定義為級聯通道矩陣 $\mathbf{D}_k = \mathrm{diag}(\mathbf{h}_k)\mathbf{H} \in \mathbb{C}^{L\times M}$ [1, 7]。則接收訊號可改寫為：

$$z_k = \boldsymbol{\phi}^T \mathbf{D}_k \mathbf{G}\mathbf{x} + w_k \tag{3.2}$$

其中 $\boldsymbol{\phi} = [\phi_1, \ldots, \phi_L]^T \in \mathbb{C}^{L\times 1}$ 是由 $\boldsymbol{\Phi}$ 的對角線元素組成的 RIS 相位向量。

3.2.1 相位依賴振幅 (PDA) 模型

理想的 RIS 元件僅改變訊號相位，其反射振幅恆為 1。然而，實際硬體中，反射振幅會隨相位變化而改變，此現象稱為相位依賴振幅（PDA）。為更精確地模擬此物理限制，我們採用文獻 [1] 中的模型：

$$\phi_l = \beta(\varphi_l) e^{j\varphi_l} \tag{3.3}$$

其中 $\varphi_l \in [0, 2\pi)$ 是第 l 個元件的相位，而 $\beta(\varphi_l)$ 是與相位相關的振幅，其公式為：

$$\beta(\varphi_l) = (1 - \beta_{\min}) \left(\frac{\sin(\varphi_l - \mu) + 1}{2} \right)^{\kappa} + \beta_{\min} \tag{3.4}$$

此處 $\beta_{\min} \in [0, 1]$, $\mu \geq 0$, 和 $\kappa > 0$ 是由 RIS 硬體實現決定的常數。此模型使優化問題更具挑戰性，也更貼近現實世界的物理特性。

3.2.2 通道估計誤差

在實際系統中，CSI 並非完美可知。我們考慮通道估計存在誤差，因此強化學習代理所能觀察到的級聯通道為 $\hat{\mathbf{D}}_k$：

$$\hat{\mathbf{D}}_k = \mathbf{D}_k + \mathbf{E}_k, \quad \forall k = 1, \ldots, K \tag{3.5}$$

其中 $\mathbf{E}_k \in \mathbb{C}^{L\times M}$ 是通道估計誤差矩陣，其元素為獨立同分佈（i.i.d.）的複高斯隨機變數，即 $e_{l,m}^{(k)} \sim \mathcal{CN}(0, \sigma_e^2)$ [1]。

3.3 問題定義

本研究的目標是聯合優化基地台的波束成形矩陣 $\mathbf{G}$ 和 RIS 的相位向量 $\boldsymbol{\phi}$，以最大化所選用戶群體的下行總傳輸速率（Sum-Rate）。

在給定 $\mathbf{G}$ 和 $\boldsymbol{\phi}$ 的情況下，第 k 個用戶的信號與干擾加噪聲比（SINR）為：

$$\mathrm{SINR}_k = \frac{|\boldsymbol{\phi}^T \mathbf{D}_k \mathbf{g}_k|^2}{\sum_{j\neq k} |\boldsymbol{\phi}^T \mathbf{D}_k \mathbf{g}_j|^2 + \sigma_w^2} \tag{3.6}$$

其中 $\mathbf{g}_k$ 是矩陣 $\mathbf{G}$ 的第 k 列向量。因此，第 k 個用戶的可達成速率為 $R_k = \log_2(1 + \mathrm{SINR}_k)$。系統的總傳輸速率 R_Σ 為所有用戶速率之和：

$$R_\Sigma = \sum_{k=1}^{K} R_k = \sum_{k=1}^{K} \log_2 \left(1 + \frac{|\boldsymbol{\phi}^T \mathbf{D}_k \mathbf{g}_k|^2}{\sum_{j\neq k} |\boldsymbol{\phi}^T \mathbf{D}_k \mathbf{g}_j|^2 + \sigma_w^2}\right) \tag{3.7}$$

我們的優化問題 (P1) 可以定式化為：

$$\begin{aligned} \max_{\mathbf{G},\boldsymbol{\phi}} \quad & R_\Sigma \\ \text{s.t.} \quad & \phi_l = \beta(\varphi_l) e^{j\varphi_l}, \quad \forall l = 1, \ldots, L \\ & \mathrm{tr}(\mathbf{G}\mathbf{G}^H) \leq P_t \end{aligned} \tag{3.8}$$

其中第一個約束是 RIS 的非理想 PDA 模型，第二個約束是基地台的最大傳輸功率限制。此問題是一個非凸且變數高度耦合的優化問題，因此我們採用深度強化學習來應對此一挑戰。

Chapter 4

方法設計與訓練架構

為了應對第三章所定義之高維度、非凸聯合優化問題，本研究設計了一套完整的、基於深度強化學習的智慧化網路部署與控制框架。本章將詳細介紹此框架的四大核心組成部分：(1) 基於 DBSCAN 與 Voronoi 圖的智慧城市環境生成機制；(2) DRL 代理的狀態、動作與獎勵函數設計；(3) 本研究所評估的多種 DRL 演算法；以及 (4) 為穩定訓練而設計的創新虛擬用戶補齊機制。

4.1 智慧城市環境生成機制

傳統 DRL 在通訊領域的應用中，常使用完全隨機生成的通道矩陣作為訓練數據，導致學習到的策略泛化能力差。為解決此問題，我們設計了一套更貼近現實部署邏輯的智慧城市環境生成機制。

1. 場景佈局與 **NLOS** 裝置生成：在 100x100 平方公尺的虛擬城市中，首先生成隨機但固定的多邊形和矩形建築物。隨後，在場景中生成共計 80 個 IoT 裝置，並嚴格限制這些裝置必須位於基地台的非視距（NLOS）區域內，以模擬訊號遮蔽最嚴峻的場景。

2. **DBSCAN** 用戶群體化：為了模擬用戶的群聚特性，我們採用 DBSCAN 演算法對這 80 個裝置進行分群。DBSCAN 根據鄰域半徑（$\epsilon = 8$ 公尺）和最小樣本數（min_samples=1）將地理位置相近的裝置劃分為同一群體。為配合後續 DRL 模型的輸入維度，我們進一步將規模大於 4 的群體進行切分，確保最終每個用戶群體最多包含 4 個裝置。

3. **Voronoi** 圖候選點生成：為了找到部署 RIS 的最佳潛在位置，我們引入了 Voronoi 圖。以場景中的建築物中心、基地台位置等作為生成元，構建 Voronoi 圖。該圖

的邊緣代表了與多個障礙物等距的路徑，這些路徑上的頂點自然成為了部署空中平台的優良候選點。

4. 候選點篩選與服務分配：我們從 Voronoi 頂點、亮暗區邊界點等位置提取大量候選點，並進行嚴格篩選，確保最終的停留點滿足以下條件：位於基地台的視距（LoS）範圍內、不在建築物內部、且與基地台的距離不超過 50 公尺。最後，系統會為每個用戶群體指派一個能提供最佳覆蓋的 RIS 停留點。

4.2 強化學習框架設計

我們將此優化問題建模為一個馬可夫決策過程（MDP），其各項元素設計如下：

- 狀態空間 $\mathcal{S}$ **(State):** 狀態向量 s_t 由以下幾部分串接而成：前一時刻的動作 a_{t-1}、分配給每個用戶的傳輸功率與接收功率、以及估計的級聯通道矩陣 $\hat{\mathbf{D}}_k$ 的實部與虛部。總狀態維度為 $2(MK + L) + 2K + 2KLM$。為提升學習效能，我們對每個時間步的狀態向量進行白化（Whitening）處理。

- 動作空間 $\mathcal{A}$ **(Action):** 動作 a_t 是代理輸出的控制決策，由波束成形矩陣 $\mathbf{G}$ 和 RIS 相位向量 ϕ 的實部與虛部串接而成，總動作維度為 $2(MK + L)$。神經網路輸出的原始動作值會經過正規化處理，以滿足基地台的總功率限制和 RIS 的相位模長約束。

- 獎勵函數 R **(Reward):** 獎勵函數直接反映了我們的優化目標。在每個時間步 t，代理執行動作 a_t 後，環境會根據式 (3.7) 計算出對應的總傳輸速率 R_Σ 作為即時獎勵 r_t。

4.3 深度強化學習演算法

本研究對多種主流及先進的 DRL 演算法進行了全面的性能評估。

- **Soft Actor-Critic (SAC):** 一種基於最大熵強化學習的 off-policy 演算法。我們設置了兩種 SAC 變體：
  - **SAC (Golden):** 代理能獲取完美的 CSI 且不受 PDA 效應影響，作為性能的理論上限。

  - **SAC (Mismatch):** 代理僅能獲取帶有誤差的 CSI，並且環境中存在 PDA 效應。

- **Beta-Space Exploration SAC:** 為了解決 SAC (Mismatch) 中因模型失配導致的性能下降，我們採用了此增強型演算法。它額外引入一個 Explorer 網路，透過最大化預測誤差來引導代理探索那些因模型失配而難以評估的區域，從而間接學習到真實的環境模型。

- **Deep Deterministic Policy Gradient (DDPG):** 一種經典的 off-policy 演算法，使用確定性策略並透過添加噪聲進行探索。它作為一個重要的 off-policy 基準與 SAC 進行比較。

- **Proximal Policy Optimization (PPO):** 一種主流的 on-policy 演算法，以其訓練的穩定性和魯棒性著稱。它透過 Clipped Surrogate Objective 來限制策略更新的幅度。PPO 作為 on-policy 方法的代表，與前述 off-policy 方法形成對比。

4.4 虛擬用戶補齊機制

在我們的環境生成機制中，DBSCAN 分群的結果可能導致某些用戶群體的規模小於我們設定的標準大小（$K = 4$）。如果直接將不同維度的狀態輸入 DRL 模型，會導致訓練不穩定甚至失敗。為了解決這個問題，我們設計了一套創新的虛擬用戶補齊機制。其工作原理如下：當一個 RIS 停留點實際服務的用戶數 $K_{real} < K$ 時，系統會自動創建 $K - K_{real}$ 個「虛擬用戶」。這些虛擬用戶的地理位置被設定為與該群體中距離 RIS 最近的真實用戶相同。如此一來，從 DRL 代理的角度看，它始終在為一個包含 $K = 4$ 個用戶的群體服務，其接收的狀態向量和輸出的動作向量維度始終保持不變。此機制巧妙地將動態變化的用戶數量問題，轉化為一個固定維度的學習問題，極大地增強了 DRL 模型訓練的穩定性和對不同規模用戶群體的適用性，是本研究方法論上的一個關鍵創新。

Chapter 5

實驗結果與分析

本章旨在呈現並分析模擬實驗結果。我們將依序評估不同強化學習模型在訓練過程中的收斂表現，並深入探討各策略在非視距（NLOS）主導的城市環境中，於不同 RIS 規模和停留點的性能差異，以全面驗證我們所提出框架的有效性。

5.1 實驗參數配置

我們的實驗參數基於系統模型與 DRL 演算法的標準設定，詳見表 5.1 與表 5.2。

Table 5.1: 模擬環境與系統參數設定

參數	數值
環境參數	
城市大小	$100 \times 100\ m^2$
總 IoT 裝置數	80
基地台位置	(50, 50, 15) m
RIS/UAV 高度	15 m
DBSCAN 鄰域半徑 (ϵ)	8 m
DBSCAN 最小樣本數	1
通訊參數	
BS 天線數 (M)	4
每群組用戶數 (K)	4
RIS 元件數 (L)	16, 32, 64
BS 總傳輸功率 (P_t)	30 dBm (1 W)
AWGN 變異數 (σ_w^2)	1×10^{-2}
通道估計誤差變異數 (σ_e^2)	1×10^{-2}
PDA 模型參數	
最小振幅 ($\beta_{\min}$)	0.3 (L=16), 0.6 (L=32, 64)
振幅衰減因子 (κ)	1.5

Table 5.2: DRL 演算法超參數設定

通用超參數	數值
學習率 (Actor & Critic)	1×10^{-3}
網路隱藏層	2 層, 每層 256 個神經元 (ReLU)
總訓練步數	20,000
Off-Policy (SAC, DDPG) 參數	
經驗回放緩衝區大小	20,000
批次大小	16
目標網路更新率 (τ)	1×10^{-3}
SAC 熵係數 (α)	0.2 (自動調整)
On-Policy (PPO) 參數	
每次更新步數 (n_steps)	2048
更新輪數 (n_epochs)	10
裁剪範圍 (clip_range)	0.2
熵係數 (ent_coef)	0.01

5.2 模型訓練收斂性分析

圖 5.1、5.2 與 5.3 分別展示了在 RIS 元件數為 16、32 與 64 時，五種 DRL 模型在訓練過程中的平均移動獎勵 (Sum-Rate) 收斂曲線。

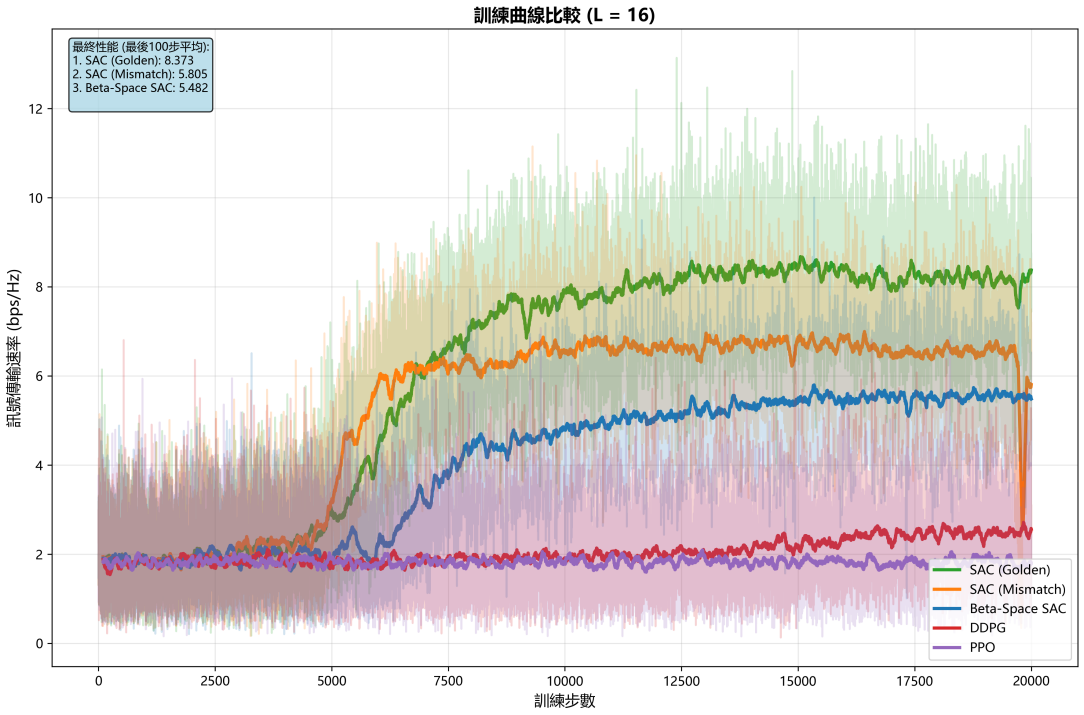


Figure 5.1: 模型訓練收斂曲線 ($L = 16$)

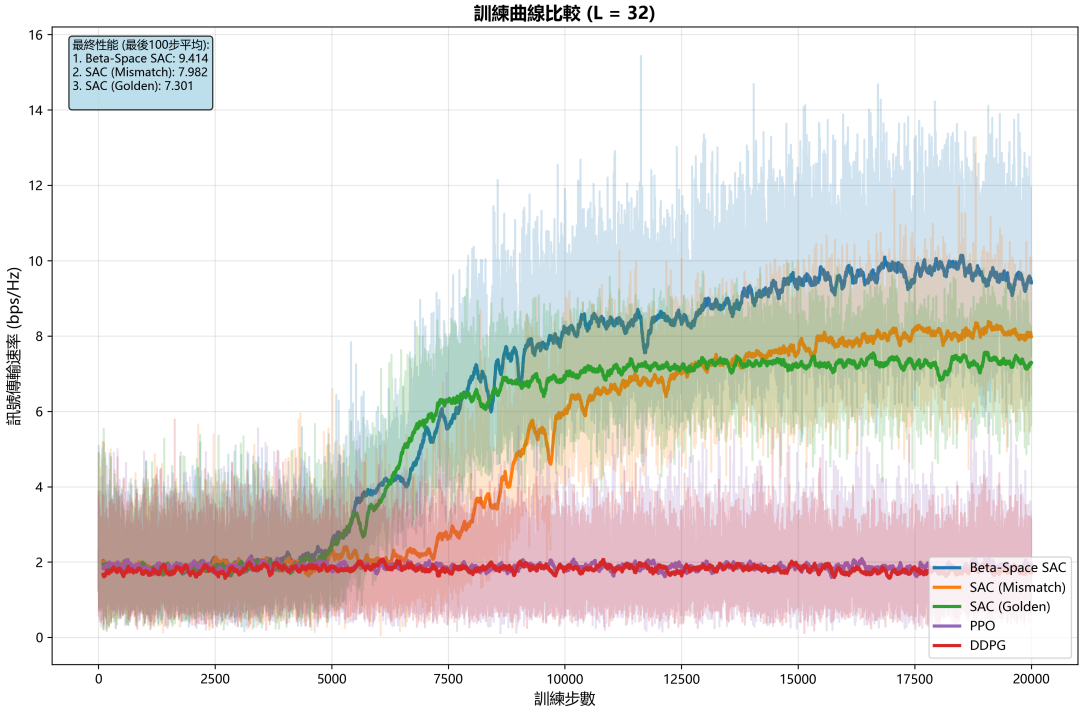


Figure 5.2: 模型訓練收斂曲線 ($L = 32$)

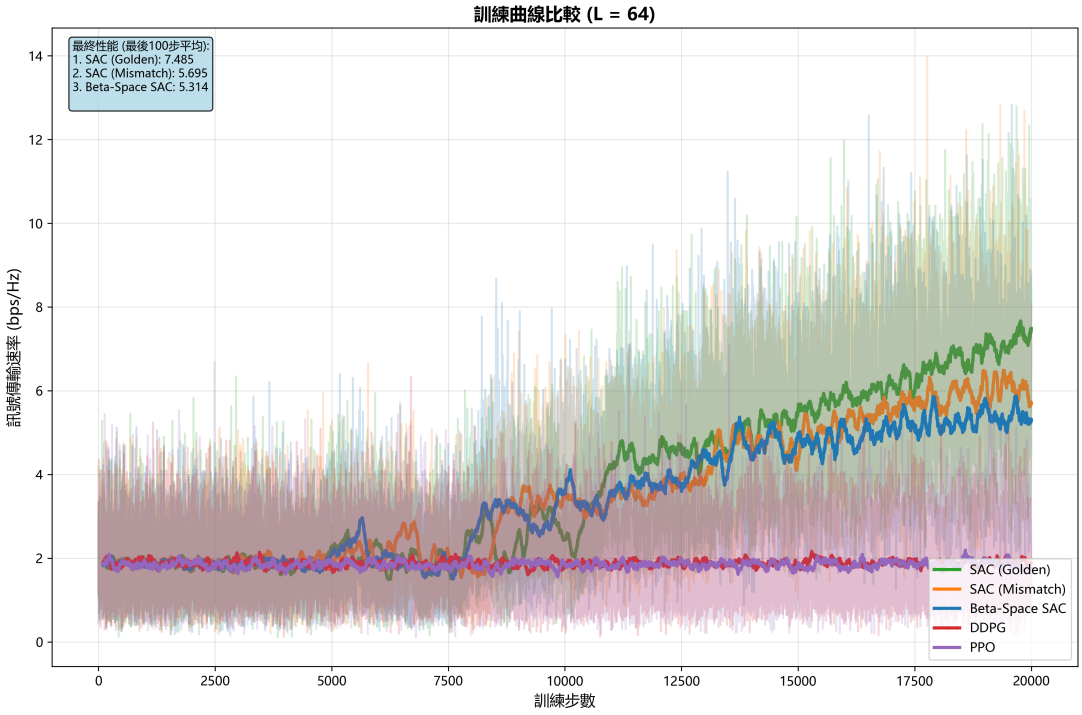


Figure 5.3: 模型訓練收斂曲線 ($L = 64$)

從這些收斂曲線中，我們可以觀察到以下關鍵趨勢：

- 演算法性能層次分明：在所有 RIS 規模下，演算法的最終性能表現出清晰的層次。Beta-Space SAC 和兩種標準 SAC 變體顯著優於 DDPG 和 PPO。這表明在

我們所設定的高維度、含非理想效應的 RIS 控制問題中，基於最大熵框架的 SAC 系列演算法比傳統的 DDPG 和 PPO 更具優勢。

- **Beta-Space Exploration 的優越性：** **Beta-Space Exploration SAC**（藍線）在考慮硬體失配的演算法中表現最佳。以 $L = 32$ 為例（圖 5.2），其最終收斂性能達到 9.414 bps/Hz，不僅遠高於 SAC (Mismatch) 的 7.982 bps/Hz，甚至超越了理想條件下的 SAC (Golden) 的 7.301 bps/Hz。這有力地證明其 Explorer 網路成功地適應了 PDA 效應，並找到了比理想模型更優的控制策略。

- **DDPG 與 PPO 的表現：** DDPG（紅線）和 PPO（紫線）雖然也能收斂，但其最終性能遠低於 SAC 系列演算法，普遍收斂在 2-3 bps/Hz 的水平。這可能是因為 DDPG 的確定性策略加噪聲的探索方式，以及 PPO 的 on-policy 採樣效率，在應對 RIS 相位空間的複雜性時效率不高。

5.3 NLOS 場景性能比較分析

為了評估各演算法在真實部署場景中的性能，我們在一個固定的、由 22 個 RIS 停留點組成的 NLOS 環境中進行了測試。用戶與基地台之間沒有直接視距，通訊完全依賴 RIS 反射。圖 5.4 展示了此測試環境的佈局。

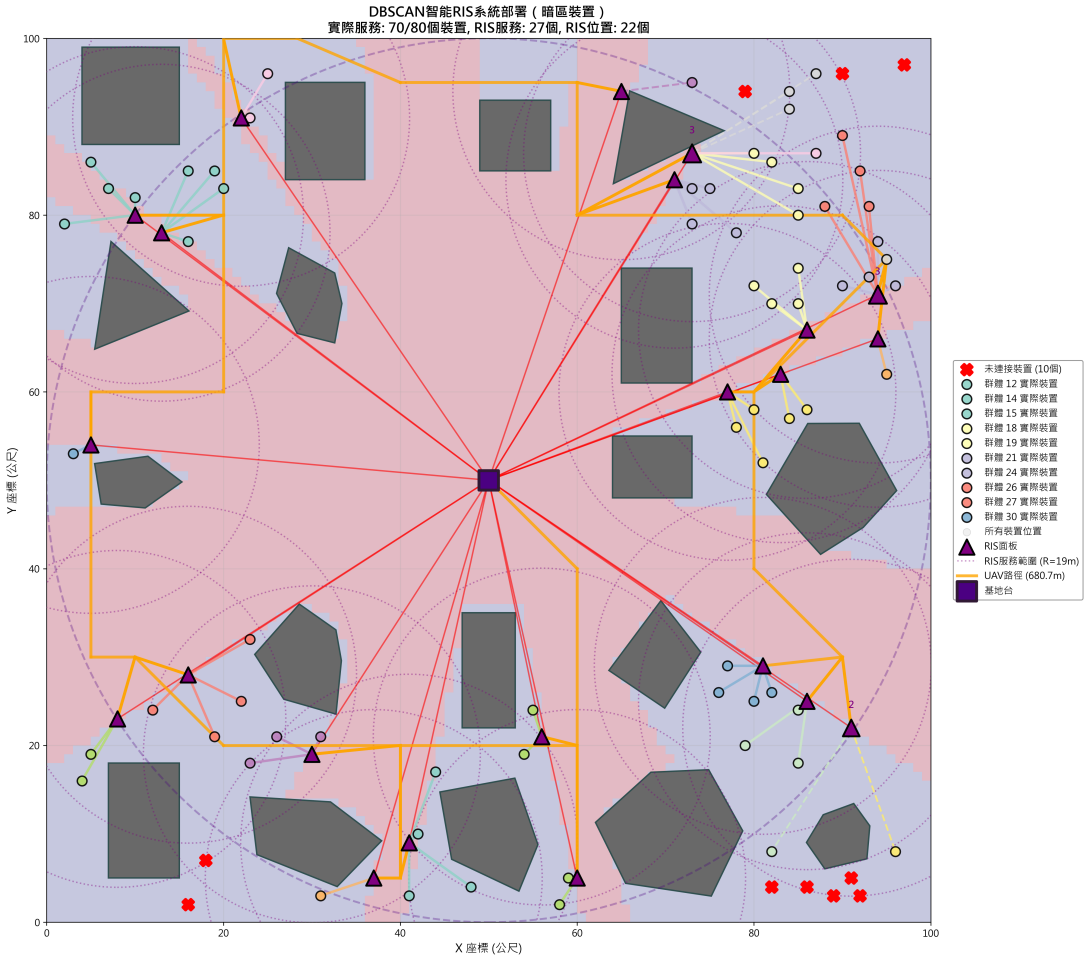


Figure 5.4: NLOS 測試環境佈局 (BS、22 個 RIS 停留點、80 個 IoT 裝置)

5.3.1 各停留點的性能比較

圖 5.5、5.6 與 5.7 展示了各演算法在 10 個代表性停留點的平均傳輸速率。

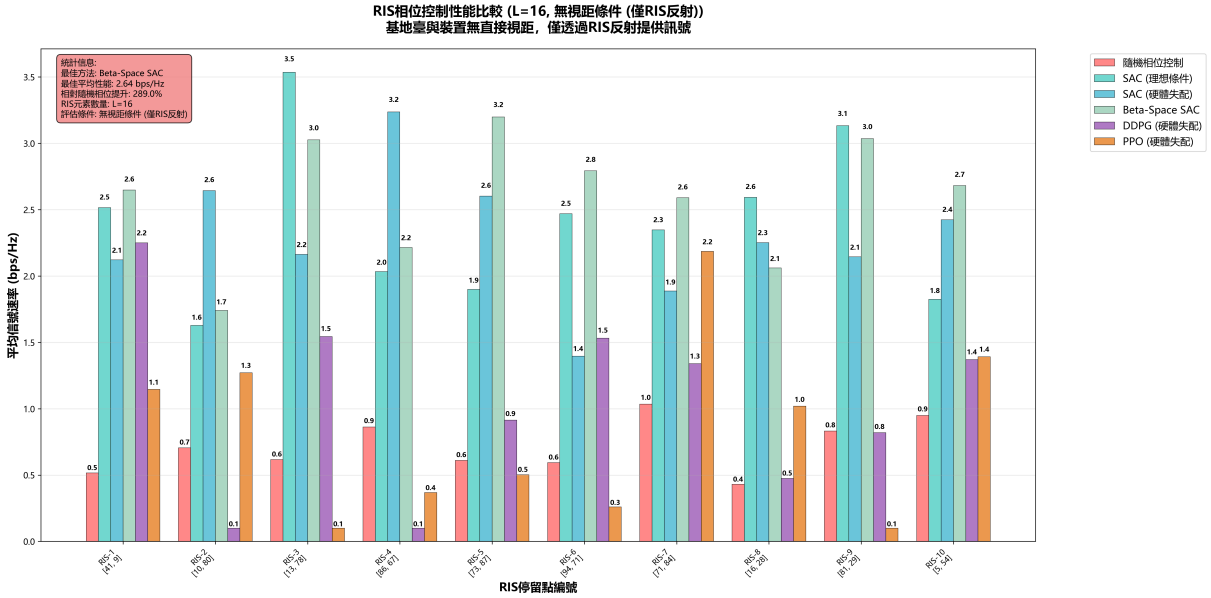


Figure 5.5: 各停留點的服務速率比較 (L=16, NLOS)

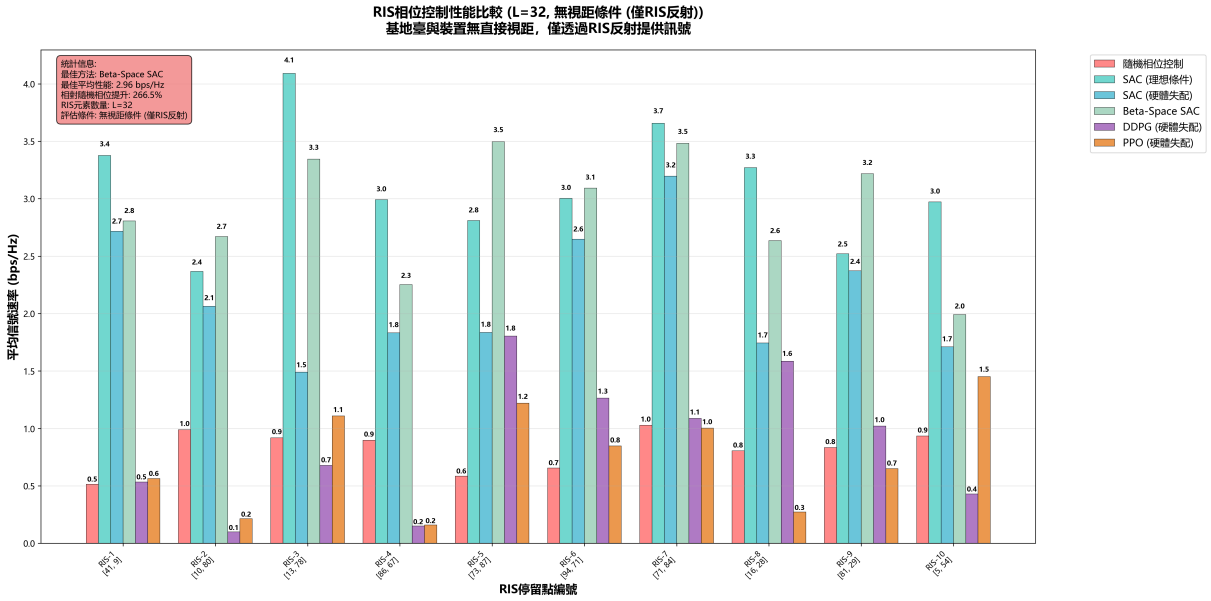


Figure 5.6: 各停留點的服務速率比較 (L=32, NLOS)

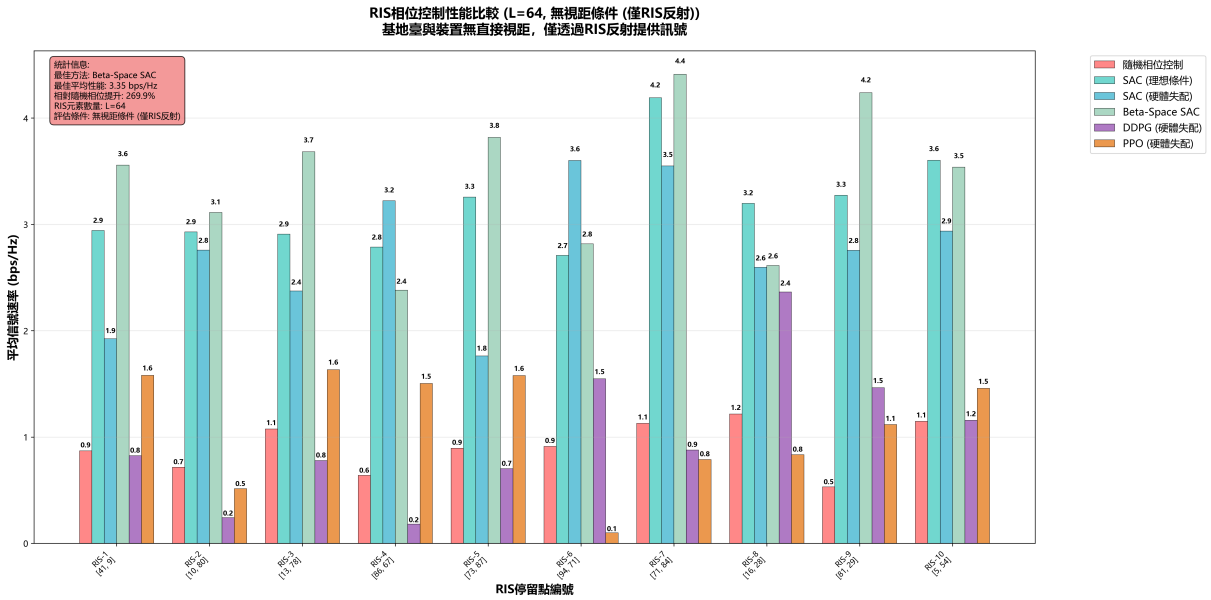


Figure 5.7: 各停留點的服務速率比較 (L=64, NLOS)

這些圖表直觀地反映了不同演算法在特定地理位置的性能差異：

- **SAC** 系列的穩定優勢：在幾乎所有停留點，三種 SAC 變體（淺藍、青色、藍綠色）的性能都遠超 DDPG（紫色）、PPO（橘色）和隨機相位（紅色）。這表明 SAC 框架對 RIS 相位優化問題具有普遍的適應性。

- **Beta-Space SAC** 的卓越表現： **Beta-Space SAC**（淺藍色）在絕大多數情況下取得了最佳性能。例如，在 $L = 64$ 的設定下（圖 5.7），於 RIS-7 停留點，其傳輸速率達到了 4.4 bps/Hz，顯著高於 SAC (Mismatch) 的 4.2 bps/Hz 和 DDPG 的 1.6 bps/Hz。這再次證明了其在應對硬體失配時的魯棒性。

- **RIS** 規模的影響：比較三張圖可以發現，隨著 RIS 元件數從 16 增加到 64，所有演算法的性能都得到了顯著提升，這符合 RIS 元件越多、波束成形增益越高的物理規律。

5.3.2 所有停留點的平均性能分析

為了得到更具統計意義的結論，我們計算了所有 22 個停留點的平均性能，並將結果繪製在圖 5.8、5.9 與 5.10 中。

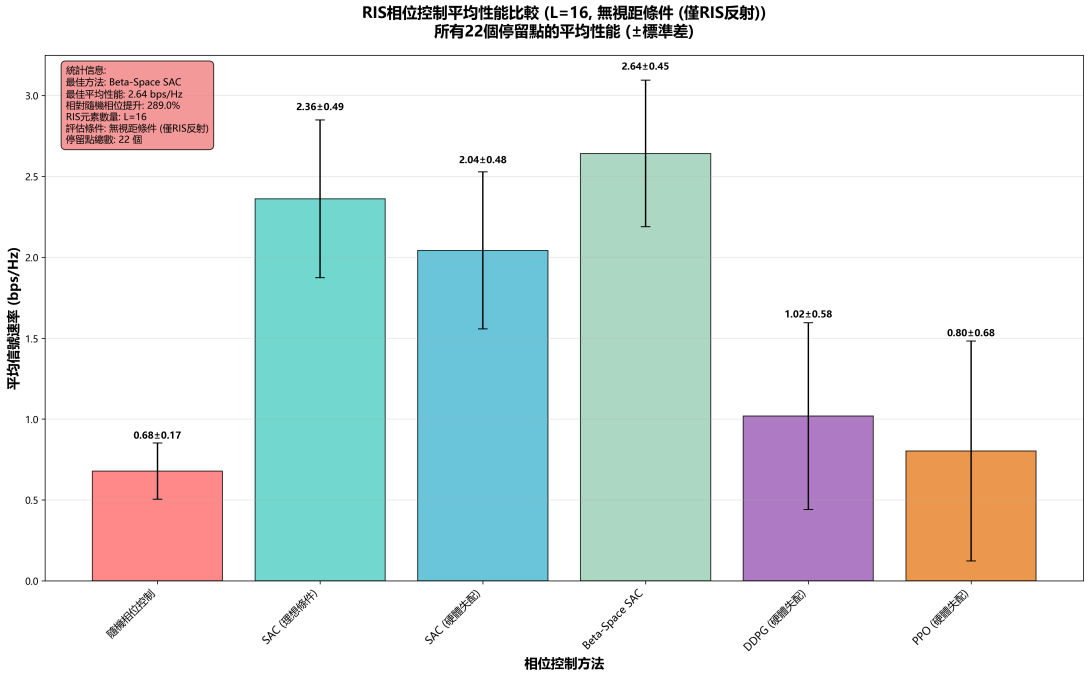


Figure 5.8: 所有停留點的平均性能比較 (L=16, NLOS)

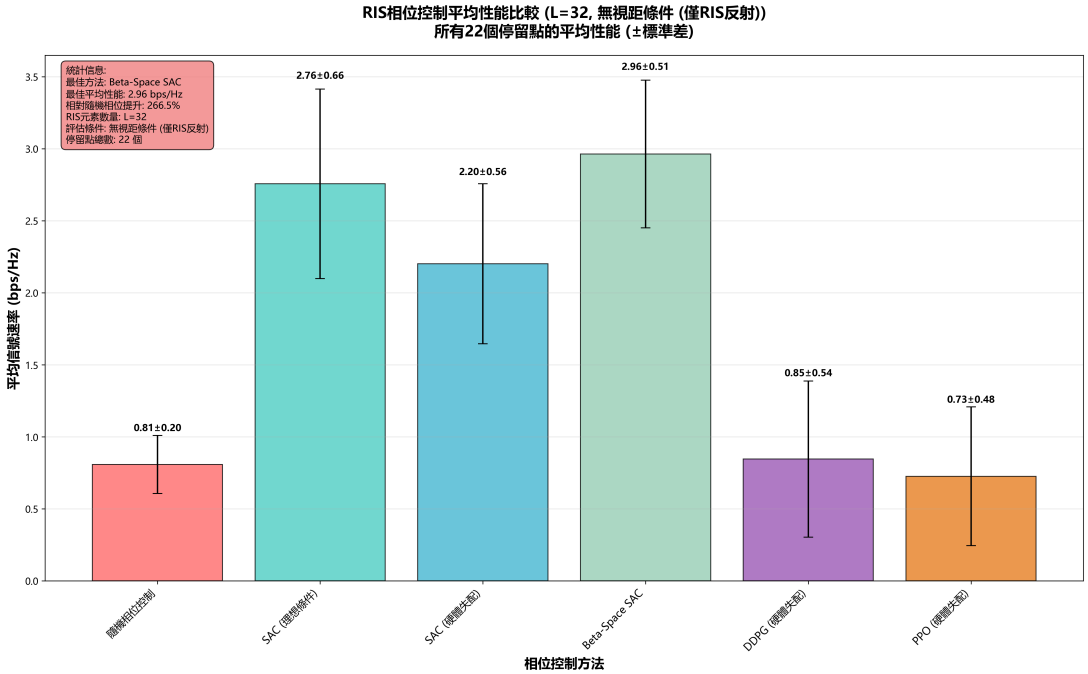


Figure 5.9: 所有停留點的平均性能比較 (L=32, NLOS)

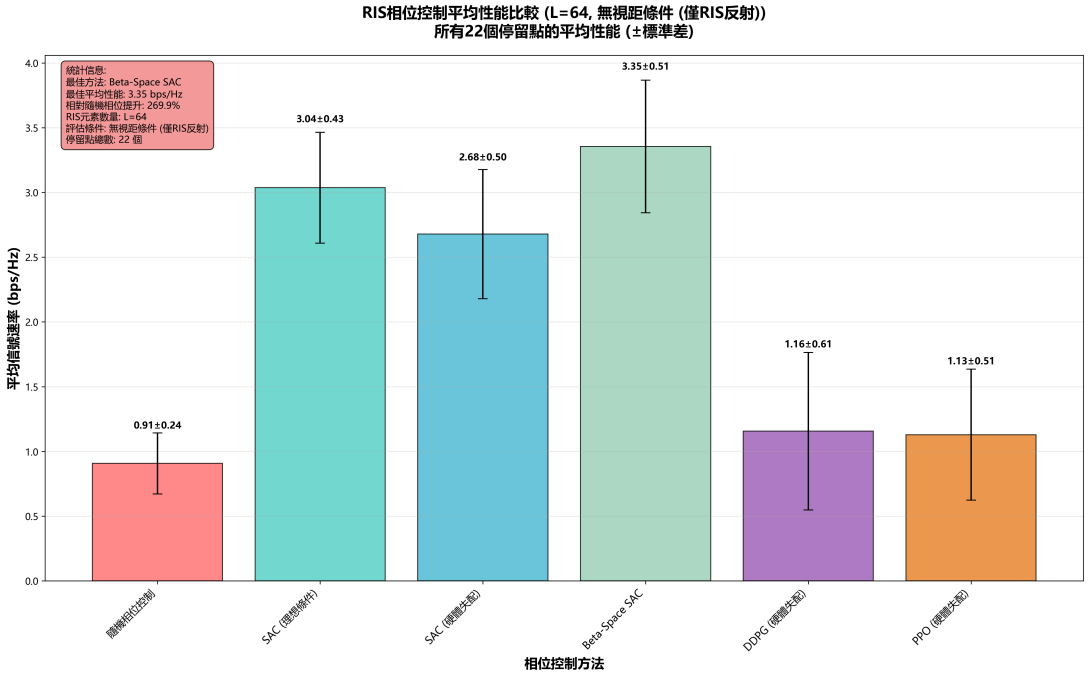


Figure 5.10: 所有停留點的平均性能比較 (L=64, NLOS)

這些平均性能圖提供了最終的、決定性的結論：

- **Beta-Space SAC** 的壓倒性優勢：在所有 RIS 規模下，Beta-Space SAC 的平均性能均為最高。以最具代表性的 $L = 64$ 為例（圖 5.10），Beta-Space SAC 的平均傳輸速率達到了 3.35 ± 0.51 bps/Hz。
- 與基準演算法的量化比較 $(L = 64)$：
  - 相較於 **SAC (Mismatch)**（2.68 ± 0.50 bps/Hz），Beta-Space SAC 性能提升了約 **25.0%**。
  - 相較於 **DDPG**（1.16 ± 0.61 bps/Hz），性能提升了約 **188.8%**。
  - 相較於 **PPO**（1.13 ± 0.51 bps/Hz），性能提升了約 **196.5%**。
  - 相較於隨機相位（0.91 ± 0.24 bps/Hz），性能提升了約 **268.1%**。
- 結論的穩健性：這一性能排序在 $L = 16$ 和 $L = 32$ 的設定下同樣成立，表明 Beta-Space SAC 的優越性並非偶然，而是在不同 RIS 規模下都具備的穩健特性。標準差（誤差棒）的大小也反映了演算法在不同地理位置性能的穩定性，其中 SAC 系列演算法的相對標準差普遍小於 DDPG 和 PPO，顯示出更好的泛化能力。

5.4 本章總結

本章的實驗結果從訓練收斂性、特定位置性能和平均性能三個層面，系統性地驗證了本研究的假設。在我們設計的、更貼近現實的 DBSCAN 用戶群體化與 NLOS 主導的城市環境中，專為應對硬體失配而設計的 Beta-Space Exploration SAC 演算法展現出全面的優勢。它不僅學習效率高，而且在各種測試場景下均能提供最優的傳輸速率，顯著超越了包括標準 SAC、DDPG 和 PPO 在內的所有基準方法。

Chapter 6

結論與未來展望

6.1 研究結論

本研究以智慧城市中的物聯網（IoT）數據收集為應用場景，針對無人機（UAV）搭載可重構智慧表面（RIS）所面臨的通訊挑戰，進行了深入的探討與驗證。透過整合先進的用戶群體化機制與多種深度強化學習（DRL）演算法，本研究成功建立了一套具備環境適應能力的智慧相位控制框架。主要的研究結論可歸納如下：

1. 成功構建並驗證了結構化的 **UAV-RIS** 模擬框架：本研究創新的引入了基於 DBSCAN 的用戶群體化和基於 Voronoi 圖的停留點生成機制。此舉不僅使模擬環境更貼近真實城市中用戶的群聚分佈，也為 DRL 代理提供了更具結構意義的學習任務，有效提升了訓練的針對性與最終策略的實用性。

2. 全面評估並確立了 **DRL** 演算法的性能層級：在我們設計的、更具挑戰性的 NLOS 主導場景中，實驗結果清晰地表明，基於最大熵框架的 SAC 系列演算法在解決 RIS 相位優化問題上，顯著優於傳統的 DDPG 和 PPO 演算法。

3. **Beta-Space Exploration SAC** 演算法的卓越性能與魯棒性：在考慮了相位依賴振幅（PDA）與不完美通道狀態資訊（CSI）的現實（Mismatch）場景中，Beta-Space Exploration SAC 演算法展現出壓倒性的優勢。其平均傳輸速率不僅遠超所有基準演算法，更證明了其 Explorer 網路能夠有效學習並補償真實世界的硬體非理想性，是解決模型失配問題的有效方案。

4.「虛擬用戶補齊機制」的有效性：該機制成功解決了因用戶群體規模動態變化而導致的 DRL 模型輸入維度不一致問題，確保了模型訓練的穩定性，是將 DRL 應用於此類實際部署場景的一個關鍵技術創新。

綜上所述，本研究不僅驗證了 UAV-RIS 系統在智慧城市數據收集中的應用潛力，更提供了一套從環境生成、演算法比較到性能評估的完整且務實的解決方案，為未來可重構智慧通訊網路的自適應部署提供了堅實的技術依據和實證數據。

6.2 後續研究建議

基於本研究的成果與最新的學術前沿，我們建議未來的研究可從以下幾個邏輯清晰、極具前瞻性的方向進行結構化擴展，這將使本研究從一個深入的通訊優化問題，提升為一個更具宏觀視野的研究議程：

- 未來方向一：整合感知與通訊的 **ISAC-RIS** 系統：本研究專注於通訊效能。下一步應將 UAV 的任務範疇從純通訊平台擴展至具備感知能力的雙功能平台。
  - 具體研究問題：如何重新設計 DRL 框架，使其能夠聯合優化通訊總傳輸速率與對特定目標的感知克拉美-羅下限 (Cramér-Rao Lower Bound, CRLB)？此舉將探索感知與通訊之間的性能權衡與協同增效 [30]。
  - 建議方法：擴展 DRL 智能體的狀態空間以包含感知目標的資訊，並設計一個能平衡通訊與感知性能的複合獎勵函數。對於多 UAV 場景，可探索基於「中心化訓練，去中心化執行」(CTDE) 典範的多智能體深度強化學習 (MADRL) 方法 [15]。
- 未來方向二：面向任務效能的語義感知型 **RIS** 系統：本研究以最大化傳輸速率為目標。一個更根本性的轉變是將優化目標從物理層的「吞吐量」提升至應用層的「任務意義」。
  - 具體研究問題：如何設計 RIS 的相位控制策略，使其目標不再是最大化接收端的 SINR，而是最大化接收端語義解碼的正確率或任務完成品質 (QoE)？一個 DRL 智能體能否根據即時通道品質與任務優先級，動態調整語義資訊的傳輸量（即壓縮等級）[31]？
  - 建議方法：將物理層的 RIS 相位控制與應用層的語義解碼器（如一個預訓練的神經網路）進行端到端聯合訓練，將語義保真度或任務準確率直接作為獎勵函數。
- 未來方向三：邁向韌性運營的主動抗干擾 **RIS** 系統：本研究假設了一個良性的通訊環境。未來的關鍵應用（如應急響應）必須考慮惡意干擾，追求系統的韌性。

- 具體研究問題：一個 DRL 智能體能否學習控制 RIS 的相位，在增強對合法用戶信號的同時，在干擾源方向上形成破壞性干涉的「零點」(Null-steering)，從而實現主動抗干擾？當干擾源同樣具備學習與適應能力時，應如何尋找魯棒的均衡策略 [32]？
- 建議方法：將問題建模為 UAV-RIS 智能體與干擾源智能體之間的動態博弈，並採用基於博弈論的 MADRL 框架（如斯塔克爾伯格博弈或零和博弈）進行求解。

總之，UAV 與 RIS 的結合為未來無線通訊帶來了廣闊的想像空間。透過整合感知能力、語義效率以及對抗韌性，我們有望構建出真正智慧化、自主化、且能應對複雜現實挑戰的下一代空天地一體化網路。

Bibliography

[1] B. Saglam, D. Gurgunoglu, and S. S. Kozat, "Deep Reinforcement Learning Based Joint Downlink Beamforming and RIS Configuration in RIS-aided MU-MISO Systems Under Hardware Impairments and Imperfect CSI," in *Proc. IEEE Int. Conf. Commun. Workshops (ICC Workshops)*, Rome, Italy, 2023, pp. 66-72.

[2] A. Al-Hilo, M. Samir, M. Elhattab, C. Assi, and S. Sharafeddine, "RIS-Assisted UAV for Timely Data Collection in IoT Networks," *IEEE Syst. J.*, vol. 17, no. 1, pp. 431-442, Mar. 2023.

[3] M. Abualhayja'a et al., "RIS-Assisted UAV for IoT Data Harvesting," in *Proc. IEEE Int. Conf. Commun. Workshops (ICC Workshops)*, Denver, CO, USA, 2024, pp. 816-821.

[4] X. Fan, M. Liu, Y. Chen, S. Sun, Z. Li, and X. Guo, "RIS-Assisted UAV for Fresh Data Collection in 3D Urban Environments: A Deep Reinforcement Learning Approach," *IEEE Trans. Veh. Technol.*, vol. 72, no. 1, pp. 632-647, Jan. 2023.

[5] D. Tyrovolas et al., "Energy-Aware Design of UAV-Mounted RIS Networks for IoT Data Collection," *IEEE Trans. Commun.*, vol. 71, no. 2, pp. 1168-1178, Feb. 2023.

[6] J. Liu and H. Zhang, "Height-Fixed UAV Enabled Energy-Efficient Data Collection in RIS-Aided Wireless Sensor Networks," *IEEE Trans. Wireless Commun.*, vol. 22, no. 11, pp. 7452-7463, Nov. 2023.

[7] H. Feng, Y. Xu, and Y. Zhao, "Deep Learning-Based Joint Channel Estimation and CSI Feedback for RIS-Assisted Communications," *IEEE Commun. Lett.*, vol. 28, no. 8, pp. 1860-1864, Aug. 2024.

[8] V. Degli-Esposti, E. M. Vitucci, M. Di Renzo, and S. A. Tretyakov, "Reradiation and Scattering From a Reconfigurable Intelligent Surface: A General Macroscopic Model," *IEEE Trans. Antennas Propag.*, vol. 70, no. 10, pp. 8691-8706, Oct. 2022.

[9] Y. Ren et al., "On Deployment Position of RIS in Wireless Communication Systems: Analysis and Experimental Results," *IEEE Wireless Commun. Lett.*, vol. 12, no. 10, pp. 1756-1760, Oct. 2023.

[10] Z. Huang, C. Liu, Y. Song, H. Zhou, and X. Shen, "Manifold Optimization Empowered Two-Timescale Channel Estimation for RIS-Assisted Systems," *IEEE Transactions on Vehicular Technology*, vol. 73, no. 10, pp. 15034-15048, Oct. 2024.

[11] D. Gurgunoglu, B. Saglam, and S. S. Kozat, "RIS-assisted MISO System with Phase Noise: Channel Estimation and Power Scaling Laws," *IEEE Transactions on Wireless Communications*, vol. 22, no. 6, pp. 3927-3941, June 2023.

[12] Z. Xiong, et al., "Robust Beamforming Design for the STAR-RIS-assisted Secure SWIPT System," *IEEE Transactions on Vehicular Technology*, vol. 73, no. 12, pp. 18605-18619, Dec. 2024.

[13] X. Pang, N. Zhao, J. Tang, C. Wu, D. Niyato, and K.-K. Wong, "IRS-Assisted Secure UAV Transmission via Joint Trajectory and Beamforming Design," *IEEE Transactions on Communications*, vol. 70, no. 2, pp. 1140-1152, Feb. 2022.

[14] W. Shi, J. Li, H. Wu, C. Zhou, N. Cheng, and X. Shen, "Drone-Cell Trajectory Planning and Resource Allocation for Highly Mobile Networks: A Hierarchical DRL Approach," *IEEE Internet of Things Journal*, vol. 8, no. 12, pp. 9800-9813, June 2021.

[15] N. Zhao, Z. Ye, Y. Pei, Y.-C. Liang, and D. Niyato, "Multi-Agent Deep Reinforcement Learning for Task Offloading in UAV-assisted Mobile Edge Computing," *IEEE Transactions on Wireless Communications*, vol. 21, no. 9, pp. 6949-6960, Sept. 2022.

[16] Z. Xie, Z. Wang, Z. Zhang, J. Wang, and Z. Jiang, "Distributed UAV Swarm for Device-Free Integrated Sensing and Communication Relying on Multi-Agent Reinforcement Learning," *IEEE Transactions on Network Science and Engineering*, 2024.

[17] Q. Huang, Z. Song, Z. Xiong, et al., "Joint resource and trajectory optimization in active IRS-aided UAV relaying networks," *IEEE Transactions on Wireless Communications*, vol. 23, no. 10, pp. 13082-13094, Oct. 2024.

[18] W. Zhuang, et al., "Learning-based reliable and secure transmission for UAV-RIS-assisted communication systems," *IEEE Transactions on Wireless Communications*, vol. 23, no. 7, pp. 6954-6967, July 2024.

[19] H. Yang, K. Lin, L. Xiao, Y. Zhao, Z. Xiong, and Z. Han, "Energy Harvesting UAV-RIS-Assisted Maritime Communications Based on Deep Reinforcement Learning Against Jamming," *IEEE Transactions on Wireless Communications*, vol. 23, no. 8, pp. 9854-9868, Aug. 2024.

[20] P. S. Aung, L. X. Nguyen, Y. K. Tun, Z. Han, and C. S. Hong, "Aerial STAR-RIS Empowered MEC: A DRL Approach for Energy Minimization," *IEEE Wireless Communications Letters*, vol. 13, no. 5, pp. 1409-1413, May 2024.

[21] Y. M. Park, S. S. Hassan, Y. K. Tun, Z. Han, and C. S. Hong, "Joint Trajectory and Resource Optimization of MEC-Assisted UAVs in Sub-THz Networks: A Resources-based Multi-Agent Proximal Policy Optimization DRL with Attention Mechanism," *IEEE Transactions on Vehicular Technology*, vol. 73, no. 2, pp. 2003-2016, Feb. 2024.

[22] Y. Emami, H. Gao, K. Li, L. Almeida, E. Tovar, and Z. Han, "Age of Information Minimization Using Multi-Agent UAVs Based on AI-Enhanced Mean Field Resource Allocation," *IEEE Transactions on Vehicular Technology*, vol. 73, no. 9, pp. 13368-13380, Sept. 2024.

[23] M. Wu, Z. Gao, Z. Wang, D. Niyato, and G. K. Karagiannidis, "STAR-RIS Aided Covert Communication in UAV Air-Ground Networks," *IEEE Journal on Selected Areas in Communications*, vol. 43, no. 1, pp. 245-259, Jan. 2025.

[24] Y. Zhang, X. Gao, N. Ye, D. Niyato, Z. Han, and K. Yang, "Joint UAV Deployment, Power Allocation, and Coalition Formation for Physical Layer Security in Heterogeneous Networks," *IEEE Transactions on Vehicular Technology*, to appear, 2025.

[25] G. Sun, W. Xie, D. Niyato, et al., "Generative AI for Advanced UAV Networking," *IEEE Network*, vol. 39, no. 4, pp. 244-253, July 2025.

[26] J. Wu, X. Fang, D. Niyato, and J. Wang, "DRL Optimization Trajectory Generation via Wireless Network Intent-Guided Diffusion Models for Resource Allocation," *IEEE Internet of Things Journal*, to appear, 2025.

[27] W. Ni, Y. Liu, Z. Yang, H. Tian, and X. Shen, "Federated Learning in Multi-RIS Aided Systems," *IEEE Internet of Things Journal*, vol. 9, no. 12, pp. 9608-9624, June 2022.

[28] D. Niyato, "GoMORE: Global Model Reuse for Resource-Constrained Wireless Federated Learning," *IEEE Wireless Communications Letters*, vol. 12, no. 9, pp. 1543-1547, Sept. 2023.

[29] J. Zhou, M. Wang, D. Tian, K. Qu, G. Qu, X. Duan, and X. Shen, "Reliability-Optimal UAV-Assisted Mobile Edge Computing: Joint Resource Allocation, Data Transmission Scheduling and Motion Control," *IEEE Transactions on Mobile Computing*, to appear.

[30] A. Author et al., "Beamforming Design and Trajectory Optimization for a Multi-UAV-Assisted ISAC System," in *Proc. IEEE Int. Conf. Commun. (ICC)*, 2025, pp. 1-6.

[31] H. Hu, X. Zhu, F. Zhou, W. Wu, et al., "Resource Allocation for Multi-Modal Semantic Communication in UAV Collaborative Networks," *IEEE Transactions on Communications*, vol. PP, no. 99, pp. 1-1, Jan. 2025.

[32] Y. Liu et al., "Multi-UAV-Assisted MEC in Internet of Vehicles With Combined Multi-Modal Semantic Communication Under Jamming Attacks," *IEEE Transactions on Mobile Computing*, vol. 24, pp. 7600-7614, Aug. 2025.